

기말 프로젝트 리포트 — 초보 학습자를 위한 과학 개념 쉬운 설명 LLM

LIU QINGYI / 학번: 2023106040 / 날짜: 2026/06/14

1. 문제 정의 & 목표

- 선택한 시나리오: 10. 도메인 용어 설명가
- 프로젝트 주제: 초보 학습자를 위한 과학 개념 쉬운 설명 LLM
- 특화 도메인: 과학 개념 설명
- 목표 사용자: 과학 개념을 처음 배우는 초보 학습자

본 프로젝트는 Unsloth Studio의 웹 UI 방식이 아니라, Google Colab 환경에서 Unsloth 라이브러리를 직접 호출하는 코드 기반 방식으로 파인튜닝을 수행하였다. 모델 로드, 데이터셋 생성, QLoRA 학습, 추론 테스트, LoRA adapter 저장 및 GGUF export 과정을 모두 Colab notebook 코드로 진행하였다.

본 프로젝트는 과학 분야의 개념이나 전문 용어를 초보 학습자가 이해하기 쉬운 문장으로 설명하는 소형 LLM을 파인튜닝하는 것을 목표로 한다. 과학 분야에는 gravity, light, heat와 같이 기본적인지만 처음 배우는 학습자에게는 어렵게 느껴질 수 있는 개념이 많다.

일반적인 베이스 모델도 과학 개념을 설명할 수 있지만, 답변이 길거나 전문적인 표현이 포함되어 초보자가 바로 이해하기 어려운 경우가 있다. 따라서 본 프로젝트에서는 과학 개념을 짧은 정의와 쉬운 예시로 설명하는 모델을 만드는 데 초점을 두었다.

본 프로젝트의 성공 기준은 다음과 같다.

- 과학 개념에 대해 답변을 생성할 수 있어야 한다.
- 베이스 모델보다 짧고 핵심적인 답변을 생성하는 경향을 보여야 한다.
- 초보 학습자가 이해하기 쉬운 표현을 사용해야 한다.
- 학습 결과를 저장하고 export할 수 있어야 한다.
- 이 모델은 어려운 과학 개념을 긴 설명이 아니라 간단한 정의와 예시로 설명하는 것을 목표로 한다. 따라서 초등·중등 수준의 과학 개념 학습 보조 도구로 활용할 수 있다.

2. 베이스 모델 선택과 근거

본 프로젝트에서는 unsloth/Qwen2.5-0.5B-Instruct 모델을 베이스 모델로 선택하였다.

항목	내용
모델명	unsloth/Qwen2.5-0.5B-Instruct
모델 크기	0.5B
instruct 여부	Instruct 모델

실행 환경	Google Colab / T4 GPU
선택 이유	작은 크기, 질문-답변 형식 학습 적합성, Unsloth 지원

이 모델을 선택한 이유는 다음과 같다.

- 모델 크기가 0.5B로 비교적 작기 때문에 Google Colab의 무료 T4 GPU 환경에서도 학습이 가능하다. 본 프로젝트는 제한된 GPU 자원에서 진행되었기 때문에, 큰 모델보다 작은 instruct 모델을 사용하는 것이 적합하다고 판단하였다.
- Instruct 모델은 질문과 답변 형식의 데이터 학습에 적합하다. 본 프로젝트의 데이터는 과학 질문과 답변 형태로 구성되기 때문에, 일반 베이스 모델보다 instruct 모델이 더 적절하다.
- Unsloth에서 해당 모델을 지원하기 때문에 QLoRA 방식의 파인튜닝을 비교적 빠르게 수행할 수 있다. 이를 통해 전체 모델을 다시 학습하지 않고도 일부 adapter 파라미터만 학습하여 효율적으로 모델을 개선할 수 있었다.

[근거] 수업 저장소의 모델 선택 가이드와 Unsloth 실습 notebook에서는 Colab T4 GPU 환경에서 소형 Instruct 모델을 활용한 파인튜닝 절차를 제공한다. 이에 따라 본 프로젝트에서는 `unsloth/Qwen2.5-0.5B-Instruct`를 선택하였다.

3. 방법: LoRA / QLoRA

본 프로젝트에서는 전체 모델을 다시 학습하지 않고, 4bit QLoRA 방식으로 파인튜닝을 수행하였다.

- 선택한 방법: 4bit QLoRA 기반 파인튜닝
- 사용 도구: Unsloth
- 실행 방식: Google Colab notebook에서 코드 기반 학습 수행

QLoRA는 4bit 양자화를 적용한 모델에 LoRA adapter를 추가하여 학습하는 방식이다. LoRA는 모델 전체 파라미터를 모두 업데이트하지 않고 일부 adapter 파라미터만 학습하는 방식이며, QLoRA는 여기에 4bit 양자화를 함께 적용하여 더 적은 VRAM으로 파인튜닝을 가능하게 한다. 따라서 Google Colab T4 GPU와 같이 제한된 GPU 환경에서 효율적으로 학습을 수행할 수 있기 때문에 본 프로젝트에 적합하다고 판단하였다.

본 프로젝트는 Google Colab 환경에서 Unsloth 라이브러리와 수업 저장소의 Colab notebook을 활용하여 진행하였다. 실제 코드에서는 모델을 불러올 때 `load_in_4bit=True`로 설정하여 4bit 양자화 모델을 사용하였고, 이후 LoRA adapter를 추가하여 SFT 학습을 진행하였다. 또한 학습 후에는 LoRA adapter 저장, 추론 테스트, GGUF export까지 수행하였다. 따라서 본 프로젝트의 학습 방식은 단순 LoRA가 아니라 SFT + 4bit QLoRA로 정리할 수 있다.

[근거] LoRA(Hu et al., 2021)는 전체 모델 파라미터를 모두 학습하지 않고 adapter 파라미터만 학습하여 메모리 사용량을 줄이는 방법이며, QLoRA(Dettmers et al., 2023)는 4bit 양자화를 활용하여 제한된 GPU 메모리에서도 파인튜닝을 가능하게 하는 방법이다. 또한 수업 저장소의 Unsloth 실습 notebook에서도 Colab 환경에서 4bit 로딩과 LoRA adapter 학습을 활용한 파인튜닝 절차를 제공하므로, 본 프로젝트에서도 해당 방식을 적용하였다.

4. 데이터셋 설계

본 프로젝트에서는 수업 저장소에서 제공하는 HuggingFace 기반 데이터셋을 사용하였다. 선택한 데이터 소스는 `science_en`이며, 원본 데이터셋은 `allenai/sciq`이다. 수업 자료의 데이터셋 목록에서 `science_en`은 과학 교육 분야 데이터로 제시되어 있어, 본 프로젝트의 “과학 개념 쉬운 설명” 목표와 적합하다고 판단하였다.

항목	내용
출처	수업 저장소에서 제공하는 HuggingFace 기반 데이터셋
데이터 소스	<code>science_en</code>
원본 데이터셋 예시	<code>allenai/sciq</code>
형식	JSONL
규모	약 7,600개 학습 데이터 사용
train / valid	<code>data/hf_train.jsonl</code> , <code>data/hf_val.jsonl</code>
정제 방법	<code>fetch_hf_datasets.py</code> 스크립트로 시나리오에 맞는 형식으로 변환

사용한 데이터 생성 명령어는 다음과 같다.

- `python scripts/fetch_hf_datasets.py --per-source 8000 --val-ratio 0.05 --only science_en`

생성된 파일은 다음과 같다.

- `data/hf_train.jsonl`
- `data/hf_val.jsonl`

데이터는 JSONL 형식으로 구성되며, 기본 구조는 다음과 같다.

```
{
  "scenario_id": 10,
  "instruction": "Explain the following science concept in simple language.",
  "input": "What is gravity?",
  "output": "Gravity is a force that pulls things down toward Earth."
}
```

왜 이 데이터 선택 근거

`science_en` 데이터는 과학 질문과 답변 형태를 포함하고 있어, 모델이 과학 개념을 설명하는 방식과 답변 구조를 학습하는 데 적합하다. 따라서 10번 시나리오인 도메인 용어 설명가와 잘 맞는다고 판단하였다.

[근거] 수업 저장소의 데이터셋 설계 문서(`wiki/03`)와 `scripts/fetch_hf_datasets.py` 실습 코드를 참고하여 `science_en` 데이터를 선택하고, JSONL 형식의 `hf_train.jsonl`, `hf_val.jsonl` 파일로 변환하였다.

5. 하이퍼파라미터 설정과 근거

본 프로젝트에서 사용한 주요 하이퍼파라미터는 다음과 같다.

손잡이	사용값	근거 / 왜 이값
learning rate	2e-4	LoRA 파인튜닝에서 자주 사용되는 안정적인 학습률이며, 짧은 학습에서 빠르게 수렴하기 위해 선택하였다.
epochs	1	Colab 무료 GPU 환경과 시간 제한을 고려하여 1 epoch로 설정하였다.
LoRA r	16	작은 모델에서 충분한 표현력을 확보하면서도 메모리 사용량을 크게 늘리지 않기 위해 선택하였다.
LoRA alpha	16	LoRA rank와 균형을 맞추기 위해 설정하였다.
LoRA dropout	0.05	과적합을 줄이기 위해 사용하였다.
target modules	q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj	transformer 주요 projection layer에 adapter를 추가하여 학습 효과를 확보하기 위해 선택하였다.
batch size	2	T4 GPU 메모리 사용량을 줄이기 위해 작게 설정하였다.
gradient accumulation	4	작은 batch size의 한계를 보완하기 위해 사용하였다.
effective batch	8	batch size 2 × gradient accumulation 4로 계산된다.
max sequence length	1024	과학 개념 설명 데이터가 비교적 짧기 때문에 1024로 충분하다고 판단하였다.

하이퍼파라미터 설정은 수업 저장소의 wiki/05 문서와 LoRA 및 QLoRA 관련 문서를 참고하여 결정하였다. 전체 모델을 업데이트하지 않고 일부 adapter 파라미터만 학습하는 QLoRA 방식은 제한된 GPU 환경에서 효율적이기 때문에 본 프로젝트에 적합하였다. 또한 LoRA는 전체 모델 파라미터를 모두 업데이트하지 않고 낮은 rank의 adapter를 학습하는 방식이며, QLoRA는 4bit 양자화를 통해 제한된 GPU 메모리에서도 파인튜닝을 가능하게 하는 방법이다. 따라서 본 프로젝트에서는 LoRA 및 QLoRA 논문과 수업 저장소 wiki/05의 가이드를 참고하여 Colab T4 GPU 환경에 맞는 하이퍼파라미터를 설정하였다.

[근거] 수업 저장소의 하이퍼파라미터 가이드(wiki/05), Unsloth 실습 notebook, LoRA및QLoRA 문서를 참고하여 learning rate, LoRA rank, LoRA alpha, dropout, batch size, gradient accumulation 값을 설정하였다.

6. 학습 과정 & 모니터링

학습은 Google Colab의 T4 GPU 환경에서 진행하였다. 먼저 GPU 상태를 확인하고, Unsloth와 필요한 라이브러리를 설치하였다. 이후 수업 저장소를 clone하고, science_en 데이터셋을 받아 학습 데이터를 생성하였다.

항목	내용
학습 환경	Google Colab / T4 GPU
학습 데이터 수	약 7,600개
학습 epoch	1
총 학습 step	950 step
학습 방식	SFT + 4bit QLoRA
모니터링 방법	training loss 확인

학습 과정에서 training loss가 점진적으로 감소하는 것을 확인하였다. 학습 초반의 loss는 약 3.3188 수준이었고, 학습 마지막 단계에서는 약 1.3202 수준까지 감소하였다. 이를 통해 모델이 science_en 데이터셋의 질문-답변 패턴을 어느 정도 학습하고 있음을 확인할 수 있었다.

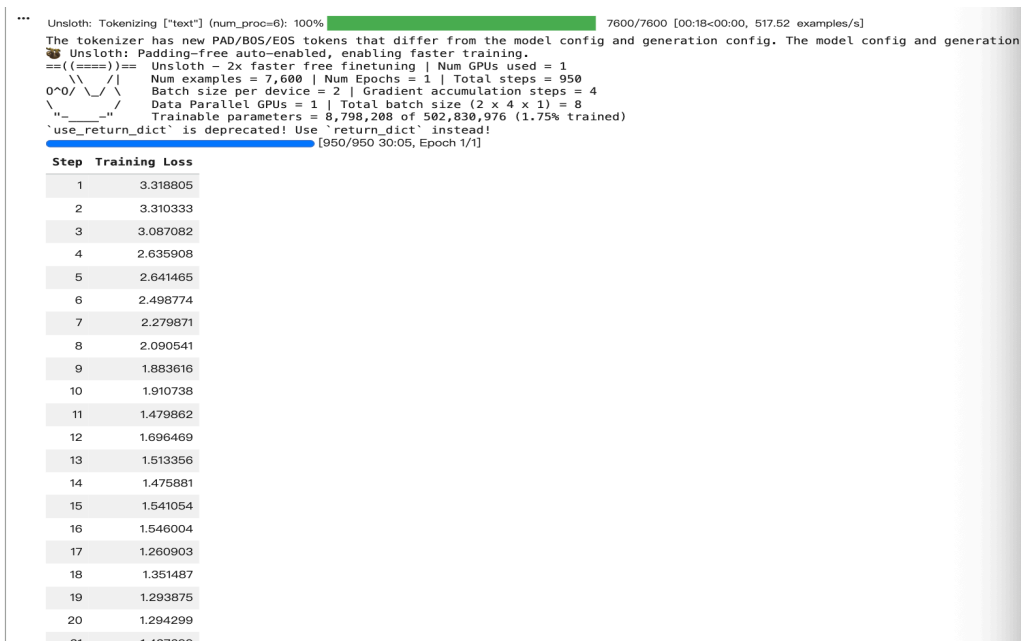


그림 1. 학습 과정의 training loss

937	1.572448
938	1.272140
939	1.495321
940	1.517013
941	1.658168
942	0.977722
943	1.510611
944	1.684676
945	1.523147
946	1.353618
947	1.477344
948	1.553465
949	1.501067
950	1.320156

그림 2. 학습 완료 결과

gradient norm / GPU 사용률 관찰:

본 프로젝트에서는 Google Colab T4 GPU 환경에서 학습을 진행하였으며, 4bit QLoRA 방식을 사용했기 때문에 학습 과정에서 GPU 메모리 부족으로 중단되지는 않았다. 또한 batch size를 2로 작게 설정하고, gradient accumulation을 4로 설정하여 제한된 GPU 환경에서도 학습이 가능하도록 조정하였다. gradient norm은 별도의 수치 그래프로 기록하지는 않았지만, 학습 과정에서 training loss가 급격히 폭발하지 않고 점진적으로 감소하는 것을 확인하였다. 따라서 학습이 완전히 불안정하게 진행되었다고 보기는 어렵다.

과적합/과소적합 판단과 그에 따라 무엇을 바꿨나:

본 프로젝트는 1 epoch만 학습했기 때문에 심한 과적합이 발생했다고 보기는 어렵다. Loss가 학습 과정에서 감소했으므로 최소한의 학습은 이루어졌다고 판단할 수 있다. 다만 학습량이 많지 않아 일부 질문에서는 출력 형식이 완전히 안정적이지 않았고, Answer가 반복되는 현상도 나타났다. 따라서 현재 결과는 기본적인 개선 가능성을 확인한 단계이며, 더 안정적인 성능을 위해서는 데이터 포맷 정제와 추가 학습이 필요하다.

[근거] 수업 실습 notebook과 하이퍼파라미터 가이드(wiki/05)를 참고하여 Colab T4 GPU 환경에 맞게 batch size, gradient accumulation, 4bit QLoRA 방식을 설정하였다. 또한 학습 과정은 training_log.png와 training_result.png 스크린샷으로 기록하였으며, training loss가 약 3.3188에서 약 1.3202로 감소한 것을 통해 모델이 학습 데이터의 패턴을 학습하고 있음을 확인하였다.

7. 구현 결과: 베이스 대비 정량·정성 비교

파인튜닝 효과를 확인하기 위해 동일한 질문을 Base Model과 Fine-tuned Model에 입력하여 답변을 비교하였다. 실제 출력 결과는 영어로 생성되었으며, 아래 표는 결과를 한국어로 요약한 것이다. 테스트 질문은 다음 세 가지를 사용하였다.

- What is gravity?
- What is light?
- What is heat?

7.1 정량 비교

항목	결과
학습 데이터 수	약 7,600개
총 학습 step	950 step
초기 training loss	약 3.3188
마지막 training loss	약 1.3202
loss 변화	감소 경향 확인
저장 결과	LoRA adapter 저장 완료
export 결과	GGUF export 완료

학습 과정에서 training loss가 감소했기 때문에 모델이 학습 데이터의 패턴을 학습하고 있음을 확인할 수 있었다. 또한 학습 후 LoRA adapter를 저장하고 GGUF 형식으로 export하여 파인튜닝 결과를 재사용 가능한 형태로 저장하였다.

7.2 정성 비교

Index	Question	Base Model	Fine-tuned Model
0	What is gravity?	Gravity is a natural force between all objects that attracts them towards each other. Imagine you're holding a ball with your hand, the ball feels heavier than it does when you release it. That's because of gravity! It's what keeps planets and stars orbiting around us.	Gravity is the force that pulls objects toward each other. It's what keeps Earth in orbit around the Sun. Answer: the force that pulls objects toward each other.
1	What is light?	Light is a form of energy that travels through space and interacts with matter. It's what we see as colors when we look at objects, like how different shades of red appear to us. Light can be seen from all directions, including inside our bodies.	Light is energy that travels through space. Light can be seen as a form of electromagnetic radiation. Answer: energy that travels through space.
2	What is heat?	Heat is a measure of energy that transfers from one object to another through contact. It's like when you feel warm when you touch a hot pan or a cup of coffee on your hand. Heat can be caused by various processes like burning, melting, or radiating sunlight.	Heat is energy that moves from one place to another. Heat can be transferred by conduction, convection, or radiation. Conduction transfers heat through direct contact. Answer: energy that moves from one place to another.

그림 3. Base Model과 Fine-tuned Model 비교 결과

프롬프트	베이스 출력 요약	파인튜닝 출력 요약	평가
What is gravity?	It explained gravity in a relatively long way and provided additional explanations using situations such as holding a ball in the hand.	It explained gravity as a force that pulls objects toward each other and answered based on the core concept.	파인튜닝 모델은 답변이 더 짧고 핵심 개념 중심으로 정리되는 경향을 보였다.

What is light?	It explained light from scientific perspectives such as energy, waves, and particles in a relatively long way.	It explained light as energy that moves through space and answered relatively briefly.	베이스 모델보다 답변이 짧아졌으며 핵심 정의를 중심으로 설명하였다.
What is heat?	It explained heat as energy transfer and gave a relatively long answer including examples such as a hot pot or coffee.	It explained heat as energy that moves from one place to another.	과학 개념의 핵심 정의를 유지하면서 답변하였다.

부작용(망각·반복 등)은 없나:

전체적으로 Fine-tuned Model은 Base Model보다 답변이 짧고 핵심 개념 중심으로 정리되는 경향을 보였지만, 일부 출력에서는 Answer:가 반복되는 현상이 나타났다. 따라서 반복 출력은 일부 부작용으로 확인되었다. 반면 망각 현상은 테스트 질문이 과학 개념 중심으로 제한되어 있었기 때문에 명확하게 판단하기 어려웠다. 향후에는 일반 질문과 도메인 질문을 함께 평가하여 망각 여부를 더 체계적으로 확인할 필요가 있다.

[근거] 수업 과제 안내에서 베이스 모델 대비 개선 입증을 요구하였기 때문에, 동일한 질문을 Base Model과 Fine-tuned Model에 입력하여 응답 차이를 비교하였다. 비교 결과는 `model\_comparison.png` 스크린샷으로 기록하였다.

개선점 정리: 무엇이 어떻게 좋아졌는가

본 프로젝트에서 확인한 개선점은 답변의 정확도가 완전히 높아졌다는 의미보다는, 모델의 답변 방식이 프로젝트 목표에 더 가까워졌다는 점이다. 본 프로젝트의 목표는 과학 개념을 초보 학습자가 이해하기 쉬운 짧은 정의와 핵심 설명으로 제시하는 것이었다. 학습 후 training loss가 약 3.3188에서 약 1.3202로 감소하였고, 동일한 질문에 대한 Base Model과 Fine-tuned Model의 답변을 비교한 결과 Fine-tuned Model은 더 짧고 핵심 개념 중심의 답변을 생성하는 경향을 보였다. 예를 들어 Base Model은 gravity, light, heat에 대해 비교적 길게 설명하는 반면, Fine-tuned Model은 각 개념의 기본 정의를 중심으로 간단히 답변하였다. 따라서 본 프로젝트의 개선점은 “답변 길이 감소”, “핵심 개념 중심의 설명”, “도메인 설명 형식에 가까운 응답”으로 정리할 수 있다.

8. Export & 데모

학습 후 파인튜닝된 모델의 LoRA adapter를 저장하였다. 이는 전체 모델을 다시 저장하는 방식이 아니라, 파인튜닝으로 학습된 adapter만 따로 저장하는 방식이다. 따라서 이후 같은 베이스 모델에 adapter를 다시 불러와 재사용할 수 있다.

항목	내용
LoRA 저장 경로	lora_model/
내보낸 포맷	LoRA adapter, GGUF
GGUF export 결과	qwen2.5-0.5b-instruct.Q4_K_M.gguf 생성

실행 방법	Google Colab 환경에서 추론 테스트 수행
로컬 실행	GGUF 파일 생성 완료, Ollama/LM Studio 실행은 향후 계획
테스트 질문	What is gravity?, What is light?, What is heat?

LoRA adapter 저장에 사용한 코드는 다음과 같다.

- `model.save_pretrained("lora_model")`
- `tokenizer.save_pretrained("lora_model")`
- `print("LoRA 저장 완료 → lora_model/")`

```

1  # (1) LoRA 어댑터만 저장
2  model.save_pretrained("lora_model")
3  tokenizer.save_pretrained("lora_model")
4  print("LoRA 저장 완료 → lora_model/")
5
6  # (2) GGUF 내보내기 (필요할 때 주석 해제)
7  # model.save_pretrained_gguf("model_gguf", tokenizer, quantization_method="q4_k_m")
8
9  # (3) 구글 드라이브에 백업 (필요할 때 주석 해제)
10 # from google.colab import drive; drive.mount('/content/drive')
11 # !cp -r lora_model /content/drive/MyDrive/
12
... Unlloth: Restored added_tokens_decoder metadata in lora_model/tokenizer_config.json.
   LoRA 저장 완료 → lora_model/

```

그림 4. LoRA adapter 저장 결과

또한 모델을 로컬 실행에 활용할 수 있는 형태로 만들기 위해 GGUF export를 수행하였다. Colab에서 q4_k_m 양자화 방식으로 GGUF 변환을 진행하였고, 최종적으로 qwen2.5-0.5b-instruct.Q4_K_M.gguf 파일이 생성되었다. 출력 화면에서 All GGUF conversions completed successfully 메시지를 확인할 수 있었다.

1

그림 5. GGUF export 결과

마지막으로 저장된 파인튜닝 모델이 실제로 답변을 생성하는지 확인하기 위해 Colab 환경에서 추론 테스트를 진행하였다.

```

Both 'max_new_tokens' (=80) and 'max_length' (=32768) seem to have been set. 'max_new_tokens' will take precedence. Please refer to the documentation for more information. (https://huggingface.co/docs/transformers/main/en/main\_classes/text\_generation)
=====
Question: What is gravity?
Answer:
Both 'max_new_tokens' (=80) and 'max_length' (=32768) seem to have been set. 'max_new_tokens' will take precedence. Please refer to the documentation for more information. (https://huggingface.co/docs/transformers/main/en/main\_classes/text\_generation)
Gravity is the force that attracts all objects with mass toward each other. It acts between any two masses, but it does not act directly on a single object. Gravity can be described by Newton's Law of universal gravitation.

Answer: the force that attracts all objects with mass toward each other

=====

Question: What is Light?
Answer:
Both 'max_new_tokens' (=80) and 'max_length' (=32768) seem to have been set. 'max_new_tokens' will take precedence. Please refer to the documentation for more information. (https://huggingface.co/docs/transformers/main/en/main\_classes/text\_generation)
Light is a form of energy. It travels through space and can be reflected, refracted, or absorbed by matter.

Answer: a form of energy

=====

Question: What is heat?
Answer:
Heat is the energy of motion. It can be transferred from one place to another by a transfer of energy.

Answer: enervoy of motion

```

그림 6. 파인튜닝 모델 추론 예시

추론 결과를 보면, 파인튜닝 모델은 과학 개념 질문에 대해 실제 답변을 생성할 수 있었으며, 질문의 핵심 개념을 중심으로 설명하는 경향을 보였다.

〔근거〕 수업 과제 안내의 Export , 실행 요구사항에 따라 LoRA adapter를 `lora\_model/` 폴더에 저장하고, 추가로 GGUF 형식 export를 수행하였다. export 결과는 `export\_result.png`와 `gguf export result.png`로 기록하였다.

9. 한계 & 다음 단계

본 프로젝트의 한계점은 다음과 같다.

- 학습 데이터가 영어 과학 개념 중심으로 구성되어 있어 한국어 설명 능력은 충분히 확인하지 못하였다. 프로젝트 주제는 초보 학습자를 위한 과학 개념 설명이지만, 실제 학습 데이터는 science_en을 사용했기 때문에 영어 설명 능력에 더 초점이 맞추어졌다.
- 학습 epoch를 1로 설정했기 때문에 모델이 충분히 깊게 학습되었다고 보기는 어렵다. Colab 환경과 시간 제한을 고려하여 짧게 학습했지만, 더 안정적인 성능을 위해서는 epoch 수와 데이터 품질 조정이 필요하다.
- Fine-tuned Model의 출력에서 일부 반복 표현이 나타났다. 예를 들어 Answer:와 같은 단어가 반복되는 현상이 있었는데, 이는 데이터 포맷이나 generation 설정을 더 정리하면 개선될 수 있다.
- 평가가 정량적 지표보다는 Base Model과 Fine-tuned Model의 응답 비교 중심으로 이루어졌다. 향후에는 답변 길이, 쉬운 표현 사용 여부, 정답 정확도 등을 기준으로 더 체계적인 평가를 진행할 수 있다.

향후 개선 방향은 다음과 같다.

- 한국어 과학 개념 데이터셋을 추가하여 한국어 설명 능력을 강화한다.
- 출력 형식을 정의 + 쉬운 예시 형태로 더 명확히 통일한다.
- LoRA rank, learning rate, epoch 수를 변경하면서 성능 차이를 비교한다.
- 더 다양한 과학 분야의 개념으로 데이터셋을 확장한다.
- Ollama 또는 LM Studio에서 GGUF 모델을 실제로 로컬 실행하는 단계까지 확장한다.

[근거] 학습 로그, 추론 결과, Base/Fine-tuned 비교 결과를 바탕으로 한계점을 정리하였다. 특히 출력 반복 현상과 영어 데이터 중심 학습의 한계는 실제 추론 결과와 모델 비교 화면에서 확인한 내용을 바탕으로 작성하였다.

10. 결론,참고문헌

본 프로젝트에서는 10번 시나리오인 도메인 용어 설명가를 기반으로, 과학 개념을 초보 학습자가 이해하기 쉬운 문장으로 설명하는 LLM을 파인튜닝하였다. 베이스 모델로는 unsloth/Qwen2.5-0.5B-Instruct를 사용하였고, 수업 저장소에서 제공하는 science_en 데이터셋을 활용하였다.

학습은 Google Colab T4 GPU 환경에서 Unsloth 코드 기반으로 진행되었으며, 4bit QLoRA 방식을 사용하여 제한된 자원에서도 파인튜닝을 수행할 수 있었다. 학습 과정에서 training loss가 감소하는 것을 확인하였고, 학습 후 모델은 gravity, light, heat와 같은 과학 개념에 대해 답변을 생성할 수 있었다.

또한 학습 후 LoRA adapter를 lora_model/ 폴더에 저장하였고, 추가로 GGUF 형식으로 export하여 qwen2.5-0.5b-instruct.Q4_K_M.gguf 파일을 생성하였다. 이를 통해 베이스 모델 선택, 데이터셋 설계, QLoRA 학습, 베이스 대비 개선 확인, export까지 이어지는 실제 파인튜닝 파이프라인을 수행하였다.

참고문헌

- 수업 저장소 edu-llm-colab-unsloth 및 Unsloth 실습 notebook
- 수업 저장소 wiki/03, 데이터셋 설계 문서

- 수업 저장소 [wiki/05](#), 하이퍼파라미터 설정 문서
- Unsloth Documentation 및 Fine-tuning Guide
- Hugging Face Datasets Documentation
- Hugging Face Datasets, [allenai/sciq](#)
- Hu et al. (2021). LoRA: Low-Rank Adaptation of Large Language Models. [arXiv:2106.09685](#)
- Dettmers et al. (2023). QLoRA: Efficient Finetuning of Quantized LLMs. [arXiv:2305.14314](#)

부록: 재현 정보

항목	내용
환경	Google Colab / T4 GPU
베이스 모델	unsloth/Qwen2.5-0.5B-Instruct
데이터셋	science_en
학습 방식	4bit QLoRA
학습 epoch	1
학습 step	950
LoRA rank	16
LoRA alpha	16
LoRA dropout	0.05
learning rate	2e-4
batch size	2
gradient accumulation	4
max sequence length	1024
random seed	3407
export	LoRA adapter 저장 및 GGUF export